

최적 분할 모델 선택을 위한 LLM 기반 모델 라우팅 오케스트레이터 개발

Development of an LLM-Based Model Routing Orchestrator for Optimal Segmentation Model Selection

Abstract

의료영상 분할은 정량 분석과 진단 보조에 활용되는 핵심 기술이지만, 공개 모델은 장기와 영상 종류에 따라 성능 차이가 크며 실제 추론 시점에는 정답 마스크(Ground Truth, GT)가 없어 최적 모델을 직접 판단하기 어렵다. 따라서 본 연구에서는 대형 언어 모델(Large Language Model, LLM)이 장기별 후보 모델의 실행 결과와 후보 점수표(candidate scorecard)를 해석하고, 시스템이 강제 제약 조건(hard constraint)과 대체 선택(fallback)을 함께 검증하는 모델 라우팅 오케스트레이터(orchestrator)를 제안한다.

실험 결과, 흉부 X선(Chest X-ray, CXR) 폐, CXR 심장, 전산화 단층촬영(Computed Tomography, CT) 폐, CT 심장 네 조건에서 각각 50개의 사례(case), 총 200개 case에서 제안 시스템은 189개 case에서 사후 평가 기준 최고 다이스 유사 계수(Dice Similarity Coefficient, DSC) 모델과 일치하여 전체 라우팅 일치율을 0.9450을 기록하였다. 조건별 라우팅 일치율은 각각 0.9400, 0.9800, 0.8600, 1.0000이었고, 선택된 최종 마스크의 전체 평균 DSC와 교집합-합집합 비율(Intersection over Union, IoU)은 0.9532와 0.9122였으며, LLM 라우터는 결정론적 routing score 선택과 동일한 정량 결과를 보였다.

이는 현재 구조에서 LLM이 입력 영상의 해부학적 특징을 직접 관독하거나 분할 정확도를 임의로 판단하는 것이 아니라, 후보 모델이 생성한 결과와 점수 근거를 장기별 문맥에서 구조화하여 선택을 수행하는 오케스트레이션 계층으로 동작했음을 의미한다. 현재 시스템은 후보 모델 수와 데이터셋 범위가 제한적이며 3개 case에서 fallback 선택이 발생하였으므로, 향후 입력 영상의 품질, 촬영 범위, 장기 경계 가시성과 같은 영상 특징을 추가하여 장기별 LLM 에이전트가 모델별 실패 패턴과 자연어 제약 조건을 함께 반영하는 구조로 확장할 계획이다.

결론적으로, 본 연구에서는 LLM이 임상적 정확도를 직접 판단하는 방식이 아니라 장기별 후보 모델 실행

결과와 점수 근거를 구조화하고 선택 이유를 생성하는 오케스트레이터로 동작함으로써, GT가 없는 추론 환경에서 장기별 분할 모델 선택 과정을 설명 가능하게 보조할 수 있음을 확인하였다.

I. 서론

1.1 관련 연구

의료영상분할은 CXR 및 CT 영상에서 폐, 심장 등 해부학적 구조를 분리하여 정량 분석과 진단 보조에 활용되는 핵심 기술이다. 분할 성능은 일반적으로 예측 마스크와 정답 마스크(GT)의 중첩 정도를 측정하는 Dice Similarity Coefficient(DSC)와 Intersection over Union(IoU)로 평가된다[1],[2].

그러나 실제 추론 환경에서는 GT가 존재하지 않기 때문에, 입력 영상별로 어떤 후보 분할 모델이 가장 적절한지 직접 판단하기 어렵다. 한편 최근 LLM은 자연어 요청 해석, 조건 기반 선택, 복수 후보 중 적절한 대상을 선택하는 라우팅 구조에 활용되고 있으며 [3],[4], MedVersa는 의료영상 해석 과정에서 LLM을 오케스트레이터로 활용할 수 있음을 보였다[7].

본 연구는 이러한 흐름을 의료영상분할 모델 선택 문제로 확장하되, LLM이 의료영상의 임상적 정확도를 직접 판단하는 것이 아니라 후보 모델의 실행 상태, 사전 검증 성능, 후보 간 마스크 합의도, 마스크 품질 점수를 포함한 scorecard를 해석하는 라우팅 오케스트레이터로 동작하도록 설계하였다.

1.2 연구 필요성 및 목적

실제 추론 환경에서는 정답 마스크(GT)가 없기 때문에 입력 영상별 최적 분할 모델을 직접 확인할 수 없다. 또한 공개 의료영상분할 모델은 특정 장기, 영상 종류, 데이터셋에 특화되어 있어 하나의 모델을 모든 CXR 및 CT 입력에 고정적으로 적용하기 어렵다.

본 연구는 이러한 문제를 해결하기 위해 사용자 요청에서 대상 장기와 영상 종류를 해석하고, 이에 맞는 후보 모델군을 실행한 뒤 후보 마스크 간 합의도, 마

스크 품질 점수, 사전 검증 성능을 결합한 후보 점수표(scorecard)를 구성한다. LLM은 입력 영상의 임상적 정확도를 직접 판단하지 않고, 이 scorecard를 해석하여 최종 모델 선택을 보조하며, 시스템은 hard constraint와 fallback 규칙을 통해 실행 실패 또는 비정상 후보 선택을 방지한다.

본 연구는 CXR/CT와 폐/심장 조건의 총 200개 case에서 제안 구조의 라우팅 성능을 정량적으로 평가하고, LLM의 역할을 단순 성능 향상이 아닌 scorecard 해석 및 선택 근거 구조화 관점에서 분석한다.

II. 본론

2.1 시스템 개요

제안 시스템은 요청 파서(request parser), 모델 레지스트리, 후보 모델 실행 래퍼(wrapper), 후보 마스크 비교 모듈, 후보 점수표 생성기, LLM 라우터, 결과 검증 및 fallback 모듈, 결과 저장 모듈로 구성된다.

사용자는 “폐 CT 분할해줘”, “CXR 심장 분할해줘”와 같은 자연어 요청을 입력한다. 시스템은 요청과 입력 파일 형식을 바탕으로 대상 장기, 영상 종류, 실행 우선순위 또는 상위 k개(top-k) 설정을 해석한다. 이후 모델 레지스트리에서 장기와 영상 종류에 맞는 후보 모델군을 구성하고, 각 후보 모델을 공통 실행 wrapper를 통해 실행하여 후보 마스크를 생성한다.

생성된 후보 마스크는 동일한 형태(shape)로 정규화된 뒤 서로 비교된다. 시스템은 후보 마스크 간 합의도를 계산하고, 각 후보에 대해 합의 IoU(consensus IoU), 합의 DSC(consensus DSC), 평균 쌍별 IoU(average pairwise IoU), 마스크 면적 비율(mask area fraction), 마스크 품질 점수(mask quality score), 실행 상태를 산출한다. 이 값들은 사전 검증 성능에서 얻은 사전 라우팅 점수(prior routing score)와 함께 후보 점수표(candidate scorecard)를 구성한다.

LLM은 후보 점수표를 입력으로 받아 점수 근거를 해석하고 최종 모델을 선택한다. 이후 시스템은 LLM 출력이 강제 제약 조건(hard constraint)을 위반하는지 검사하며, 실행 실패 모델, 비활성 모델, routing score가 0.0000인 모델이 선택된 경우 fallback 규칙을 적용한다. 이때 LLM은 다음 조건을 반드시 따른다.

1. 실행 상태가 success가 아닌 모델은 선택하지 않는다.
2. selection_enabled=false인 모델은 선택하지 않는다.
3. routing score가 0.0000인 모델은 선택하지 않는다.
4. 비어 있는 마스크 또는 오류가 발생한 모델은 선택

하지 않는다.

5. 임상적 정확도를 주장하지 않고, 후보 점수표에 포함된 근거만 사용한다.




그림 1. 제안한 LLM 분할 모델 라우팅 오케스트레이터의 전체 시스템 흐름.

그림 1은 제안 시스템의 전체 흐름을 나타낸다. 사용자의 자연어 요청과 입력 영상은 요청 파서를 통해 대상 장기와 영상 종류로 변환되고, 모델 레지스트리에 맞는 후보 모델군을 구성한다. 이후 각 후보 모델은 동일 입력에 대해 마스크를 생성하며, 시스템은 후보 마스크를 정규화하고 합의도, 품질 점수, 실행 상태를 계산한다. 생성된 후보 점수표는 LLM 라우터에 제공되며, 최종 선택 결과는 hard constraint와 fallback 규칙을 통해 검증된 뒤 저장된다.

2.2 후보 점수표 구성

후보 점수표는 LLM이 모델을 선택하기 전에 제공받는 구조화된 입력이다. 이 점수표는 단순히 모델 이름과 과거 성능만 나열하지 않고, 현재 입력 영상에서 후보 모델들이 실제로 생성한 마스크의 합의 정도를 포함한다.

필드	의미
execution_status	모델 실행 성공 여부
prior_routing_score	과거 라우팅 점수
overlap_score	후보 간 합의 기반 점수
mask_quality_score	결과 마스크 품질 점수
routing_score	LLM 선택에 사용되는 점수

표 1. 후보 점수표의 주요 필드

routing score는 prior routing score, overlap score, mask quality score를 결합하여 계산하며, execution status가 실패인 후보나 비정상 마스크 후보는 최종 선택 대상에서 제외하였다.

$$S_r = 0.6000 \times P_r + 0.2000 \times O_r + 0.2000 \times Q_m$$

S_r = 최종라우팅 점수, P_r = 사전라우팅 점수,
 O_r = 중첩 점수, Q_m = 마스크품질 점수

2.3 후보 모델 구성

현재 시스템은 폐와 심장을 대상으로 CXR 및 CT 후보 모델을 통합하였다.

대상 장기	영상 종류	분할 네트워크
폐	X-ray	cxr_basic_anatomy_lung, torchxrayvision_pspnet_lung, imlab-uiip_lung-segmentation-2d
	CT	JoHof_lungmask, wasserth_TotalSegmentator_lung, knottwill_UNet-Small
심장	X-ray	cxr_basic_anatomy_heart, DIAGNijmegen_opencxr_heart_seg, ConstantinSeibold_ChestXRayAnatomySegmentation, torchxrayvision_pspnet_heart
	CT	wasserth_TotalSegmentator_heart, fkong7_HeartFFDNet_mmwhs, fkong7_HeartDeformNets_mmwhs

표 2. 모델 레지스트리 기반 라우팅 후보 모델.

후보모델은 CXR/CT와 폐/심장 조건별 공개 구현 및 사전학습 가중치로 구성하였으며, 주요 출처는 chest-x-ray-basic[15], TorchXRayVision[8], lung-segmentation-2d[16], OpenCXR[9], ChestXRayAnatomySegmentation[10], lungmask[11], TotalSegmentator[6], UNet-Small[12], HeartFFDNet[13], HeartDeformNets[14]이다.

2.4 데이터 구성

CXR 실험은 NIH ChestX-ray8 데이터셋[5]에서 추출한 샘플과 CheXmask 기반 마스크를 이용하여 폐와 심장 각각 50장 단위로 수행하였다. CT 실험은 Totalsegmentator_dataset[6]의 CT volume과 segmentation 마스크를 이용하여 폐와 심장 각각 50장 단위로 수행하였다.

CT 실험에서는 흉부 또는 심장 영역이 충분히 포함된 case를 확보하기 위해 GT 복셀 수 기준으로 데이터를 필터링하였다. CT 폐는 폐 GT 복셀 수 100,000개 이상, CT 심장은 심장 GT 복셀 수 10,000개 이상인 case를 사용하였다. 이 기준은 실험 데이터 구성과 사후 평가에만 사용되었으며, LLM 라우팅 입력에는 포함하지 않았다.

2.5 평가 지표

평가는 분할 성능과 라우팅 성능을 분리하여 수행한다. 분할 성능은 GT가 존재하는 실험 데이터에서 DSC로 평가하고, IoU를 보조 지표로 사용했다. DSC와 IoU는 사후 평가 지표이며, 실제 추론 시점에서

LLM이 직접 사용하는 GT 기반 정보는 아니다.

라우팅 성능은 LLM이 선택한 모델이 해당 데이터에서 최고 DSC를 기록한 모델과 일치하는 비율로 평가한다. 이 지표는 router_matched_best_dsc_rate로 기록된다. 단, 최고 DSC 모델과의 불일치(mismatch)가 항상 큰 실패를 의미하지는 않는다. 일부 CXR 폐 불일치 사례(mismatch case)는 DSC 차이가 0.0031 이하인 유사한 결과였기 때문에, 평균 DSC와 불일치 격차(mismatch gap)을 함께 해석해야 한다.

$$DSC = \frac{2|P \cap G|}{|P| + |G|}$$

P = 예측마스크의 양성 픽셀 집합

G = 정답마스크의 양성 픽셀 집합

III. 구현

3.1 실험 결과

제안 시스템은 CXR 폐, CXR 심장, CT 폐, CT 심장 네 조건을 각각 50개 case에서 평가하였다. 전체 라우팅 일치율은 0.9450이었으며, 조건별 일치율은 CXR 폐 0.9400, CXR 심장 0.9800, CT 폐 0.8600, CT 심장 1.0000이었다. 선택된 최종 마스크의 전체 평균 DSC와 IoU는 각각 0.9532와 0.9122였다.




그림 2. CXR 및 CT 조건별 제안 시스템의 선택 마스크 예시. 행은 CXR 폐, CXR 심장, CT 폐, CT 심장 순서이며, 열은 원본 영상, GT, 선택 마스크, GT와 선택 마스크의 중첩 결과를 나타낸다.

3.2 LLM 필요성 비교 실험

본 연구에서는 “최종 라우팅 점수(routing score)가 가장 높은 모델을 선택하면 되는데 LLM이 어떤 역할을 하는가?”라는 질문에 답하기 위해 추가 비교 실험을 수행하였다. 동일한 200개 case에 대해 사전 라우팅 점수(prior routing score)만 사용하는 방법, 후보 간 합의도(overlap score)만 사용하는 방법, 마스크 품질 점수(mask quality score)만 사용하는 방법, 최종 라우팅 점수만 사용하는 방법, LLM 라우터, 그리고 사후 평가 기준 최고 DSC 모델(oracle)을 비교하였다. 이때 GT mask는 평가에만 사용하였고, LLM 라우팅 입력에는 제공하지 않았다.

선택 전략	최고 모델 일치율	선택모델 평균 DSC
Prior	0.9300	0.9526
Overlap	0.3500	0.7027
Quality	0.3250	0.8808
Routing score	0.9450	0.9532
LLM router	0.9450	0.9532
GT-best DSC	1.0000	0.9543

표 3. LLM 필요성 검증 실험 결과.

3.3 Discussion

실험결과, 제안시스템은 200개 case 중 189개 case에서 사후 최고 DSC 모델과 일치하여 전체 라우팅 일치율 0.9450을 보였다. 이는 후보점수표 기반 라우팅 구조가 장기와 영상종류가 달라져도 일관된 선택기준을 제공할 수 있음을 보여준다. 다만 LLM 필요성 비교 실험에서 LLM router와 Routing score only가 동일한 선택결과를 보였으므로, 본 연구의 결과를 “LLM이 단순 점수선택보다 높은 DSC를 달성했다”는 의미로 해석해서는 안 된다. 본 연구에서 LLM은 독립적인 정확도 판단자가 아니라 후보모델 실행결과와 scorecard를 장기별 문맥에서 해석하고 선택이유를 구조화하는 오케스트레이션 계층으로 동작한다. CT 폐의 낮은 일치율(0.8600)은 입력별 후보 비교의 필요성을 보여주며, CT 심장에서는 비정상적으로 큰 마스크를 억제하기 위해 mask quality score와 volume fraction guardrail이 필요함을 확인하였다.

IV. 결론 및 향후 연구 방향

본 연구에서는 최적 분할 모델 선택을 위한 LLM 기반 모델 라우팅 오케스트레이터를 제안하고, 폐와 심장을 대상으로 CXR 및 CT 후보 모델을 통합하였다. 제안 시스템은 사용자 자연어 요청을 해석하고, 장기와 modality에 맞는 후보 모델을 실행한 뒤, 후보 mask의 합의도와 사전 검증 성능을 결합한 후보 점수

표를 구성한다. LLM은 이 점수표를 해석하여 선택 이유를 생성하고, 시스템은 hard constraint와 fallback을 통해 최종 선택을 검증한다.

완료된 50장 단위 실험에서 CXR 폐, CXR 심장, CT 폐, CT 심장 네 조건을 합산한 전체 라우팅 일치율은 0.9450이었다. 조건별 라우팅 일치율은 각각 0.9400, 0.9800, 0.8600, 1.0000이었고, 선택된 최종 마스크의 전체 평균 DSC와 IoU는 각각 0.9532와 0.9122였다. 이 수치는 개별 후보 모델의 성능을 강조하기 위한 것이 아니라, 제안한 오케스트레이터가 후보 모델 군 안에서 사후 평가 기준 높은 DSC를 보인 결과를 선택했는지를 평가하기 위한 지표이다.

추가 비교 실험에서 LLM router는 Routing score only와 동일한 전체 최고 DSC 모델 일치율 0.9450, 평균 DSC 0.9532, 평균 IoU 0.9122를 보였다. 이는 LLM이 결정론적 점수 선택을 무시하고 임의 판단을 수행하지 않았으며, 구조화된 후보 점수표를 장기별 모델 선택 근거로 일관되게 해석했음을 의미한다. 특히 GT가 없는 추론 환경에서 후보 mask 간 합의도와 prior evidence를 함께 사용하는 구조는 단순 고정 모델 선택보다 유연한 라우팅 가능성을 제공한다. 향후에는 입력 영상의 품질, 촬영 범위, 장기 경계 가시성, 모델별 실패 패턴, 사용자 제약 조건을 함께 반영하여 장기별 LLM 에이전트가 “어떤 특징의 영상에서 어떤 모델이 적합한지” 판단하는 구조로 확장할 수 있다.

향후 연구에서는 첫째, CT 심장 fallback case를 분석하여 장기별 mask quality score와 volume fraction 기준을 더 세분화할 계획이다. 둘째, 누적 실험 결과를 agent memory에 반영하여 장기별 prior score를 지속적으로 보정하고, 폐 에이전트와 심장 에이전트가 서로 다른 선택 기준을 갖도록 확장할 예정이다. 셋째, 입력 영상의 품질, 촬영 범위, 장기 경계 가시성 같은 image-level feature를 추출하여 LLM 입력에 추가할 예정이다. 넷째, 사용자가 속도 우선, 특정 모델 제외, GPU 사용 불가와 같은 자연어 제약 조건을 제시하는 상황을 추가하여 LLM 오케스트레이션의 필요성을 더 직접적으로 검증할 예정이다. 다섯째, left lung, right lung 등 세부 장기 단위 실험과 외부 데이터셋 검증을 통해 장기별 LLM 에이전트 기반 라우팅 성능의 일반화 가능성을 평가할 예정이다.

참고문헌

- [1] Dice, L. R. “Measures of the Amount of Ecologic Association Between Species.” *Ecology*, 26(3), 297–302, 1945.

- [2] Jaccard, P. "Distribution de la flore alpine dans le Bassin des Dranses et dans quelques regions voisines." *Bulletin de la Societe Vaudoise des Sciences Naturelles*, 37, 241–272, 1901.
- [3] Chen, L., Zaharia, M., and Zou, J. "FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance." *arXiv:2305.05176*, 2023.
- [4] Ong, I., Almahairi, A., Wu, V., Chiang, W.-L., Wu, T., Gonzalez, J. E., Kadous, M. W., and Stoica, I. "RouteLLM: Learning to Route LLMs with Preference Data." *arXiv:2406.18665*, 2024.
- [5] Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., and Summers, R. M. "ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases." *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [6] Wasserthal, J., Breit, H.-C., Meyer, M. T., et al. "TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images." *Radiology: Artificial Intelligence*, 2023.
- [7] Zhou, H.-Y., Acosta, J. N., Adithan, S., Datta, S., Topol, E. J., and Rajpurkar, P. "MedVersa: A Generalist Foundation Model for Medical Image Interpretation." *arXiv:2405.07988*, 2024.
- [8] Cohen, J. P., Viviano, J. D., Bertin, P., Morrison, P., Torabian, P., Guarrera, M., Lungren, M. P., Chaudhari, A., Brooks, R., Hashir, M., and Bertrand, H. "TorchXRyVision: A Library of Chest X-ray Datasets and Models." *arXiv:2111.00595*, 2021.
- [9] DIAGNijmegen. "OpenCXR: A Collection of Open-source Algorithms for Chest X-ray Analysis." *GitHub repository*, <https://github.com/DIAGNijmegen/opencxr>.
- [10] Seibold, C., Jaus, A., Fink, M. A., Kim, M. S., Reiß, S., Kleesiek, J., and Stiefelhagen, R. "Accurate Fine-Grained Segmentation of Human Anatomy in Radiographs via Volumetric Pseudo-Labeling." *arXiv:2306.03934*, 2023.
- [11] Hofmanninger, J., Prayer, F., Pan, J., Röhrich, S., Prosch, H., and Langs, G. "Automatic Lung Segmentation in Routine Imaging Is Primarily a Data Diversity Problem, Not a Methodology Problem." *European Radiology Experimental*, 4, 50, 2020.
- [12] knottwill. "UNet-Small: U-Net Small for Fast, Accurate Lung CT Segmentation." *GitHub repository*, <https://github.com/knottwill/UNet-Small>.
- [13] Kong, F., and Shadden, S. C. "Whole Heart Mesh Generation for Image-Based Computational Simulations by Learning Free-Form Deformations." *MICCAI*, 2021.
- [14] Kong, F., and Shadden, S. C. "Learning Whole Heart Mesh Generation from Patient Images for Computational Simulations." *arXiv:2203.10517*, 2022.
- [15] ianpan. "chest-x-ray-basic." *Hugging Face model repository*, <https://huggingface.co/ianpan/chest-x-ray-basic>.
- [16] imlab-uiip. "lung-segmentation-2d: Lung Fields Segmentation on CXR Images Using Convolutional Neural Networks." *GitHub repository*, <https://github.com/imlab-uiip/lung-segmentation-2d>.